

Aplicações da Lei dos Grandes Números: um estudo comparativo entre um fenômeno discreto e um contínuo

Júlio Neto Victor Couto Miguel Figueiredo

Disciplina de Probabilidade — Bacharelado em Sistemas de Informação
CEFET-MG

29 de junho de 2026

Resumo

Este trabalho ilustra empiricamente a Lei dos Grandes Números (LGN) por meio de dois conjuntos de dados de naturezas opostas: os sorteios da Mega-Sena (fenômeno *discreto*, com probabilidades conhecidas *a priori*) e os retornos diários de uma ação negociada na bolsa (fenômeno *contínuo*, com média populacional *estimada* dos próprios dados). Mostra-se que a frequência relativa de um evento converge para sua probabilidade teórica e que a média amostral converge para a esperança, em ambos os casos. O argumento central é o contraste de *velocidade*: embora a LGN seja universal, o ritmo da convergência é governado pelo coeficiente de variação $CV = \sigma/|\mu|$, via erro relativo $CV/\sqrt{n}$. Enquanto a loteria ($CV \approx 0,57$) converge em poucas dezenas de observações, os retornos ($CV \approx 18$) exigiriam mais de um século de dados para a mesma precisão. Discute-se ainda a hipótese de independência e a transição natural da LGN para o Teorema Central do Limite.

1 Introdução

A Lei dos Grandes Números (LGN) é um dos pilares da teoria da probabilidade. Em termos intuitivos, ela formaliza a ideia de que, ao repetir um experimento aleatório muitas vezes, a *média* dos resultados observados se aproxima do valor *esperado*, e a *frequência relativa* de um evento se aproxima de sua *probabilidade*. É a ponte rigorosa entre o conceito abstrato de probabilidade e aquilo que efetivamente medimos no mundo.

O objetivo deste trabalho é *demonstrar visualmente*, com dados reais, as duas faces dessa lei e — sobretudo — evidenciar que a sua *velocidade* de convergência depende fortemente da variabilidade dos dados. Para isso, escolhemos dois conjuntos deliberadamente contrastantes:

- **Caso discreto:** o histórico de sorteios da **Mega-Sena**, em que as probabilidades são conhecidas por construção ($p = 6/60 = 0,10$ para uma dezena fixa; média $\mu = 30,5$ por dezena);
- **Caso contínuo:** os **retornos diários** de uma ação, em que a média populacional é minúscula frente a uma volatilidade muito alta e precisa ser *estimada* dos dados.

A comparação entre os dois mostra que a LGN *vale nos dois casos* (universalidade), mas que a rapidez é radicalmente diferente — um ponto que conduz naturalmente ao Teorema Central do Limite (TCL).

2 Fundamentação teórica

2.1 Esperança, variância e média amostral

Seja $X_1, X_2, \dots, X_n$ uma sequência de variáveis aleatórias independentes e identicamente distribuídas (i.i.d.), com esperança e variância finitas, $\mathbb{E}[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$. A *média amostral* após n observações é

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i. \quad (1)$$

2.2 As duas formas da Lei dos Grandes Números

Lei Fraca (convergência *em probabilidade*): para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) = 0. \quad (2)$$

Lei Forte (convergência *quase certa*, mais forte):

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu\right) = 1. \quad (3)$$

Ambas afirmam que a média amostral se aproxima arbitrariamente de μ conforme n cresce.

2.3 A velocidade da convergência

A média amostral é um estimador não-viesado de μ , e sua variância *encolhe* com n :

$$\mathbb{E}[\bar{X}_n] = \mu, \quad \text{Var}(\bar{X}_n) = \frac{\sigma^2}{n} \implies \text{EP}(\bar{X}_n) = \frac{\sigma}{\sqrt{n}}. \quad (4)$$

Esse *erro padrão* $\sigma/\sqrt{n}$ é o conceito-chave do trabalho. Para comparar fenômenos de escalas diferentes, é útil o *erro relativo*

$$\frac{\text{EP}(\bar{X}_n)}{|\mu|} = \frac{\sigma/\sqrt{n}}{|\mu|} = \frac{\text{CV}}{\sqrt{n}}, \quad \text{CV} = \frac{\sigma}{|\mu|}, \quad (5)$$

em que CV é o *coeficiente de variação*. Invertendo a Equação (5), o número de observações necessário para um erro relativo e é

$$n = \left(\frac{\text{CV}}{e}\right)^2. \quad (6)$$

A dependência quadrática implica que *ganhar um dígito de precisão* (10× menor erro) custa 100× mais dados.

2.4 Frequência relativa como caso particular

Para um evento A , defina a variável indicadora $X_i = \mathbf{1}\{A \text{ ocorre no ensaio } i\}$, de modo que $X_i \sim \text{Bernoulli}(p)$ com $\mathbb{E}[X_i] = p = \mathbb{P}(A)$. A média amostral coincide então com a frequência relativa:

$$\bar{X}_n = \frac{N_A}{n} \xrightarrow{\mathbb{P}} p \quad (n \rightarrow \infty), \quad N_A = \text{n}^\circ \text{ de ocorrências de } A. \quad (7)$$

Ou seja, *frequência relativa convergir para probabilidade* nada mais é do que a LGN aplicada a indicadores de Bernoulli.

2.5 Do limite ao formato: o Teorema Central do Limite

A LGN diz *para onde* a média converge; o Teorema Central do Limite (TCL) diz *com que forma*. Sob as mesmas hipóteses,

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad (n \rightarrow \infty), \quad (8)$$

isto é, $\bar{X}_n \approx \mathcal{N}(\mu, \sigma^2/n)$, *qualquer que seja* a distribuição de origem.

3 Dados e metodologia

3.1 Conjuntos de dados

Mega-Sena. Histórico de 2278 sorteios (de 1996 a 2018). Cada concurso sorteia 6 dezenas distintas entre 1 e 60, totalizando 13 668 dezenas. Os alvos teóricos são conhecidos: $\mathbb{P}(\text{dezena fixa}) = \binom{59}{5}/\binom{60}{6} = 0,10$; frequência de cada número = $1/60 \approx 0,0167$; e esperança por dezena $\mu = 30,5$, com variância da uniforme discreta $\sigma^2 = (60^2 - 1)/12 \approx 299,9$ ($\sigma \approx 17,32$).

Retornos financeiros. Série de 2490 retornos diários da ação PETR4.SA (2016–2026), obtida via biblioteca `yfinance` a partir do preço de fechamento ajustado P_t . Calculou-se o retorno simples $R_t = P_t/P_{t-1} - 1$ (e, alternativamente, o logarítmico $r_t = \ln(P_t/P_{t-1})$). Aqui a média populacional é *estimada* da própria série.

3.2 Ambiente computacional

A análise foi conduzida em Python (`pandas`, `numpy`, `matplotlib`) sobre um ambiente Docker reproduzível com JupyterLab. Os resultados estão organizados em três *notebooks*: caso discreto, caso contínuo e síntese. Todas as figuras deste documento foram geradas por esses *notebooks*.

4 Caso discreto: Mega-Sena

4.1 Frequência relativa $\rightarrow$ probabilidade

Fixada uma dezena k , definimos por sorteio a indicadora $X_i = \mathbf{1}\{\text{o sorteio } i \text{ contém } k\} \sim \text{Bernoulli}(0,10)$ e acompanhamos a frequência relativa acumulada $\hat{p}_n$. A Figura 1 mostra o

resultado para $k = 10$.




Figura 1: Frequência relativa acumulada da dezena 10 convergindo para a probabilidade teórica 0,10. As oscilações iniciais (entre 0 e 0,2) se amortecem conforme n cresce.

As oscilações se amortecem à medida que n aumenta — a assinatura visual da LGN. Vale uma observação de honestidade analítica: a curva termina em $\hat{p}_{2278} \approx 0,121$, e não exatamente em 0,10. Isso *não* contradiz a LGN: o erro padrão de $\hat{p}_n$ é $\sqrt{p(1-p)/n} \approx 0,0063$, de modo que o desvio observado equivale a cerca de 3,4 erros padrão. De fato, a dezena 10 está *entre as mais sorteadas* do período (empatada com a dezena 5, ambas com 276 aparições em 2278 sorteios) — ou seja, recaímos em um dos casos “mais difíceis” e, ainda assim, a frequência ficou na casa de 0,12. A lição é que 2278 ensaios ainda é pouco para um evento de $p = 0,10$, e que é o *afunilamento* das oscilações (não a igualdade exata) que evidencia a convergência.

A Figura 2 confirma que o fenômeno não depende da dezena escolhida: diferentes números convergem todos para a mesma reta 0,10.




Figura 2: Várias dezenas: todas as frequências relativas acumuladas convergem para 0,10, ilustrando que o resultado independe do número escolhido.

Olhando o resultado *final* (Figura 3), a frequência relativa de cada um dos 60 números, calculada sobre as 13 668 dezenas, oscila em torno de $1/60$ sem viés sistemático (todas

entre 0,013 e 0,020). As diferenças são flutuação amostral, coerente com um sorteio justo.




Figura 3: Frequência relativa de cada dezena no total de 13 668 sorteadas. As barras oscilam em torno da reta teórica $1/60 \approx 0,0167$.

4.2 Média amostral $\rightarrow$ esperança

Tratando as 13 668 dezenas (na ordem dos concursos) como observações, a média acumulada converge para $\mu = 30,5$ (Figura 4), terminando em $\approx 30,22$.




Figura 4: Média acumulada das dezenas convergindo para a esperança teórica 30,5.

Sobrepondo a faixa teórica $\mu \pm 2\sigma/\sqrt{n}$ (Figura 5), observa-se que a média empírica entra rapidamente no “funil” e ali permanece, confirmando o decaimento do erro na taxa $\sigma/\sqrt{n}$.




Figura 5: Média acumulada dentro da faixa teórica $\mu \pm 2\sigma/\sqrt{n}$, que afunila como $1/\sqrt{n}$.

5 Caso contínuo: retornos financeiros

5.1 A natureza dos dados

A Figura 6 mostra a série de retornos diários. A média (linha vermelha) é praticamente indistinguível de zero diante da amplitude das oscilações — imagem direta de “sinal minúsculo, ruído enorme”. Nota-se ainda o *agrupamento de volatilidade*: períodos turbulentos seguidos de períodos turbulentos.



Figura 6: Série de retornos diários. A média é quase nula frente à volatilidade, e a turbulência ocorre em ondas (*volatility clustering*).

As estatísticas-resumo confirmam o quadro: média $\hat{\mu} \approx 0,001445$ (0,14% ao dia), desvio $\sigma \approx 0,0259$ (2,59% ao dia), e portanto $CV = \sigma/|\hat{\mu}| \approx 17,9$. Pela Equação (6), atingir um erro relativo de 10% exigiria $n \approx 32\,070$ pregões — cerca de **127 anos**.

5.2 Convergência lenta e ruidosa

A média acumulada (Figura 7) passa anos longe do alvo, inclusive negativa por longos trechos, aproximando-se de $\hat{\mu}$ apenas perto do fim. O ponto final coincide com $\hat{\mu}$ por construção (o alvo é a média de toda a série); o que demonstra a LGN é o *caminho*, não o ponto final.




Figura 7: Média acumulada dos retornos: convergência lenta e ruidosa para a média estimada $\hat{\mu}$, em forte contraste com a loteria.

A faixa teórica (Figura 8) é larguíssima e afunila devagar: mesmo ao fim de uma década, ela ainda *inclui o zero*. Em termos práticos, com ~ 10 anos de dados não conseguimos afirmar com segurança que a média diária difere de zero.




Figura 8: Média acumulada e faixa $\hat{\mu} \pm 2\sigma/\sqrt{n}$. Por causa do σ elevado, a faixa permanece larga e contém o zero ao fim da série.

5.3 A variância da média encolhe como σ^2/n

Um experimento de reamostragem (*bootstrap*) confirma $\text{Var}(\bar{R}_n) = \sigma^2/n$. Para tamanhos crescentes n , a distribuição das médias amostrais se concentra em torno de $\hat{\mu}$ (Figura 9). A Tabela 1 mostra que o desvio empírico das médias coincide com o $\sigma/\sqrt{n}$ teórico.




Figura 9: Distribuição das médias amostrais para n crescente: mais altas e estreitas conforme n aumenta, todas centradas em $\hat{\mu}$.

Tabela 1: Desvio das médias amostrais (*bootstrap*, 3000 amostras) versus previsão teórica $\sigma/\sqrt{n}$.

n	desvio empírico	$\sigma/\sqrt{n}$ teórico
10	0,008237	0,008181
50	0,003725	0,003659
250	0,001638	0,001636
1000	0,000819	0,000818

6 Síntese e ponte para o Teorema Central do Limite

6.1 As duas convergências no mesmo eixo

Em escala log-log, o erro relativo $|\bar{X}_n - \mu|/|\mu|$ dos dois casos decai com a *mesma* inclinação $-\frac{1}{2}$ (a assinatura do $1/\sqrt{n}$), separado apenas pela *altura* — justamente a razão entre os coeficientes de variação (Figura 10).




Figura 10: Erro relativo da média acumulada para os dois casos, em escala log-log. As curvas têm a mesma taxa $1/\sqrt{n}$; o coeficiente de variação determina a altura.

A Tabela 2 traduz isso em custo de dados (Equação (6)).

Tabela 2: Número de observações para um dado erro relativo, por Equação (6).

Erro relativo	Mega-Sena (n)	Retornos (n)	Retornos ($\sim$ anos)
10 %	32	32 070	127
5 %	129	128 280	509
1 %	3224	3 207 000	12 726

6.2 Da LGN ao TCL

Padronizando as médias amostrais conforme a Equação (8), verifica-se a emergência da normal mesmo quando os dados de origem não são normais. Na loteria (distribuição uniforme), a aproximação é *rápida*: já em $n \approx 5\text{--}30$ o histograma coincide com a normal-padrão (Figura 11).




Figura 11: Mega-Sena: médias padronizadas convergindo para $\mathcal{N}(0,1)$ (curva vermelha). Partindo de uma uniforme, a forma de sino surge já com poucos termos.

Nos retornos (caudas pesadas), a aproximação é *mais lenta*: para n pequeno o histograma é pontiagudo e de caudas grossas, e a normal só se firma por volta de $n = 250$ (Figura 12).




Figura 12: Retornos: médias padronizadas convergindo para $\mathcal{N}(0,1)$, porém mais devagar, devido às caudas pesadas da distribuição de origem.

A mesma mensagem da LGN reaparece no TCL: a convergência ocorre nos dois casos (universalidade), mas é mais lenta onde a variabilidade é maior.

7 Discussão crítica

Alvo conhecido vs. estimado. Na loteria, comparamos as curvas com valores *deduzidos* (0,10; 1/60; 30,5), o que torna o caso um laboratório ideal. Nos retornos, o alvo μ é *estimado* da própria série — situação mais realista, em que a incerteza sobre o próprio alvo se soma à da estimativa.

Hipótese i.i.d. A LGN clássica supõe observações i.i.d. Os sorteios são fisicamente independentes entre concursos (hipótese plausível); dentro de um mesmo sorteio, contudo, as 6 dezenas são extraídas sem reposição, logo não são estritamente independentes — uma violação branda que não compromete o resultado. Já os retornos financeiros apresentam *dependência temporal* (agrupamento de volatilidade), *não-estacionariedade* e *caudas pesadas*. A aplicação da LGN/TCL nesse caso é uma *aproximação informada*, amparada por versões mais fracas dessas leis (para processos estacionários e ergódicos): a convergência ocorre, apenas mais devagar.

Lei fraca vs. forte. O que enxergamos nos gráficos — uma trajetória que se aproxima de μ e ali permanece — é a intuição da Lei Forte (convergência quase certa). A Lei Fraca faz uma afirmação sobre a probabilidade de desvio para cada n fixo. Para fins de visualização, ambas indicam o mesmo: a média converge.

8 Conclusão

A partir de dois conjuntos de dados reais e de naturezas opostas, verificamos empiricamente as duas faces da Lei dos Grandes Números: a frequência relativa converge para a probabilidade (caso particular com indicadores de Bernoulli) e a média amostral converge para a esperança. As principais conclusões são:

1. **Universalidade.** A LGN (e o TCL) valem tanto para um sorteio discreto e simétrico quanto para retornos contínuos de cauda pesada; a validade não depende da forma da distribuição.
2. **Velocidade.** O ritmo da convergência é governado pelo coeficiente de variação $CV = \sigma/|\mu|$, via erro relativo $CV/\sqrt{n}$. Com $CV \approx 0,57$, a loteria converge em dezenas de observações; com $CV \approx 18$, os retornos precisariam de cerca de 1000 vezes mais dados para a mesma precisão.
3. **Custo da precisão.** Pela relação $n = (CV/e)^2$, cada dígito adicional de precisão custa $100\times$ mais observações.
4. **Honestidade sobre as hipóteses.** A aproximação i.i.d. é quase exata na loteria e apenas aproximada nos retornos, o que reforça a leitura cuidadosa dos resultados.
5. **Da LGN ao TCL.** A LGN indica o destino da média; o TCL descreve a forma (normal) e a taxa da chegada. Juntos, explicam a centralidade das médias na estatística e por que algumas são muito mais difíceis de estimar que outras.

Em uma única frase: *a Lei dos Grandes Números é a mesma para todos os fenômenos; o que muda é a velocidade com que ela se manifesta.*

Referências

- [1] YFINANCE. *Yahoo! Finance market data downloader*. Disponível em: <https://github.com/ranaroussi/yfinance>. Acesso em: 29 jun. 2026.
- [2] BIZARRI, V. B. *Sorteios Mega-Sena*. Kaggle. Disponível em: <https://www.kaggle.com/datasets/viniciusbbizarri/sorteiosmegasena>. Acesso em: 29 jun. 2026.